Entrega de Guia 1

Programa:

Procesamiento de Datos para Modelos de Inteligencia Artificial

Ficha: 3602991

INTEGRANTES:

Dairon Arturo Salinas Mahecha

Jhonny Stiven Niño Alipio

Jose William Barrera Medina

Docente A Cargo:

Ing. Nathalia Martinez Vargas

Sena centro de materiales y ensayos

BOGOTA D.C, COLOMBIA

2026

Tabla de contenido

Actividades

2.1.1 Actividades a Desarrollar 3

2.2 Actividades de contextualización e identificación de conocimientos 5

2.3 Actividades de Apropiación del Conocimiento 14

2.4 Actividades de Transferencia de Conocimiento ..... .17

2.4.1 Desarrollo del Diccionario de Datos 17

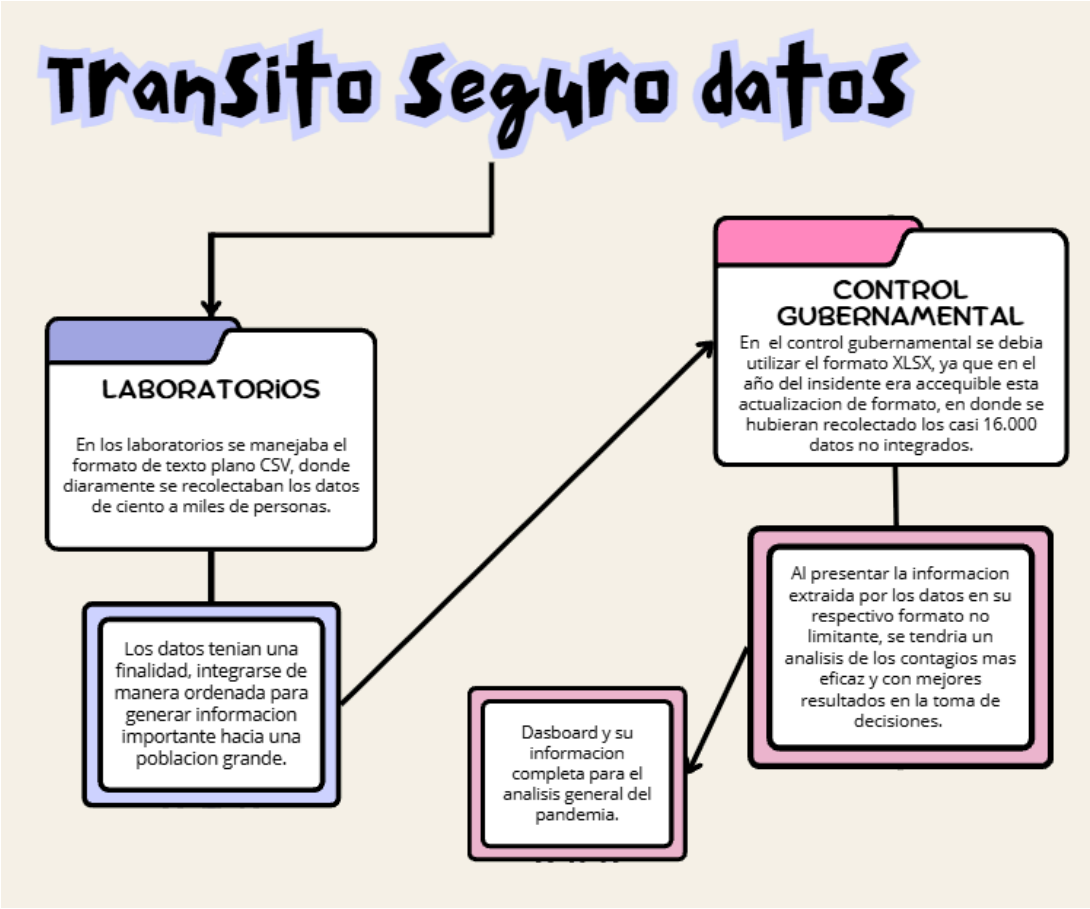
Referencias 27

2.1.1 Actividades a Desarrollar

1. Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo énfasis en sus lımites de almacenamiento (filas y columnas) e identificando en qué punto exacto fallo la integridad de los datos en el caso expuesto.
    - CSV es un formato de archivo separado por comas, almacena datos tabulares (números y texto) en texto plano, que se puede abrir en excel. En excel se puede guardar un archivo en formato (.csv), pero dado que este está formado por texto plano, se borrarán los estilos, colores, se descartaran fórmulas y cualquier configuración que haya tenido la tabla a guardar, sólo conservará la estructura. La característica más importante de este formato, es que la capacidad de datos almacenados es ilimitada.
    - En 1987, Microsoft desarrolló la primera hoja de cálculo Excel para el sistema Windows, y desde entonces el producto ha sido muy bien recibido, por lo tanto ha recibido una cantidad significativa de actualizaciones. Su principal característica es que solo tiene 65.536 filas y 256 columnas.
    - XLSX es la extensión de Microsoft Office Excel 2007/2010/2013/2016/2019 y es el formato principal de las hojas de cálculo de Excel. En comparación con ".xls", teóricamente puede almacenar 1.048.576 filas y 16.384 columnas de datos. Cuando los datos con muy extensos son difíciles de manipular en este formato, en una gran cantidad de datos es mejor utilizar, SQL, python o R.

La integridad de los datos del caso expuesto fue en el momento de la recolección de datos, al utilizar un formato ya anticuado como xls, aunque tiene la misma presentación de XLSX, la capacidad es limitada y posiblemente por ahorrar costes de una versión más reciente (en el año 2020 ya se debería utilizar XLSX) se perdieron los 15.841 datos recolectados.

2. Elaborar un esquema conceptual que ilustre cómo debió ser el tránsito seguro de la información desde los laboratorios (origen) hasta el tablero de control gubernamental (destino). Se debe justificar qué formatos (CSV o XLSX) debieron emplearse en cada etapa para garantizar la preservación de los casi 16.000 registros perdidos.



3. Redactar una conclusión analıtica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial gubernamental.

El conocimiento técnico en el análisis de datos es indispensable, especialmente en el entorno gubernamental, donde las decisiones tienen un impacto directo en la vida de las personas y pueden afectar de manera positiva o negativa a toda una nación. Por esta razón, es importante que los responsables tengan conocimientos sobre el manejo, la organización, la validación y la preservación de la información.

De igual manera, la responsabilidad ética es fundamental al momento de tomar decisiones, ya que trabajar con datos incompletos o incorrectos puede generar conclusiones equivocadas y afectar a la población. Por eso, los analistas deben aplicar principios y buenas prácticas, verificar que la información sea confiable y realizar un análisis adecuado de los resultados. La combinación del conocimiento técnico y la responsabilidad ética permite tomar decisiones más acertadas, conscientes y orientadas al bienestar de la sociedad.

2.2 Actividades de contextualización e identificación de conocimientos

Datasets seleccionados para la exploración de datos

Eje temático y justificación

El eje temático seleccionado es el medio ambiente y las condiciones climáticas en Colombia. Elegimos este tema porque nos permite conocer y analizar información relacionada con el clima y la calidad del aire en diferentes regiones del país. Además, estos datos son importantes para identificar comportamientos ambientales, reconocer posibles problemas de contaminación y comprender cómo las condiciones climáticas pueden influir en nuestro entorno.

Esta datasets es de información secundaria, donde nosotros no realizamos la extracción directa de los datos, sino es extraída de un estudio ya realizado en una plataforma libre. Los datos correspondientes de la tabla están a continuación:

1. Datasets 1: Auditoría

   Dataset seleccionado: Normales Climatológicas de Colombia

   Portal: Portal Único del Estado Colombiano

   Formato: CSV

   Enlace: https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Normales-Climatol-gicas-de-Colombia/nsz2-kzcq/data_preview

Variable	Descripción de Variables	Tipo de Variable	Clasificación
PERIODO (periodo)	Años donde se realizó la auditoría climática.	Cualitativa	Ordinal
PARÁMETRO (par_metro)	Estado en el que se tomaron los datos de la época climática.	Cualitativa	Nominal
CÓDIGO (c_digo)	Código de identificación de departamentos o	Cualitativa	Ordinal

	sectores climáticos.		
CATEGORÍA (categoria)	Datos generales de la situación monetaria de la población.	Cualitativa	Nominal
ESTACIÓN (estaci_n)	Lugar de recolección de datos de los departamentos.	Cualitativa	Nominal
MUNICIPIO (municipio)	Municipio en donde se recolectaron los datos correspondientes.	Cualitativa	Nominal
DEPARTAMENTO (departamento)	Departamento de Colombia donde se recolectaron los datos correspondientes.	Cualitativa	Nominal
ALTITUD (m) (altitud_m)	Altura en donde se encuentran las estaciones de recolección de datos en los municipios, medido en metros.	Cuantitativa	Discreta

LONGITUD (longitud)	Parte de ubicación de la estación donde se recolectaron los datos.	Cuantitativa	Continua
LATITUD (latitud)	Parte de ubicación de la estación donde se recolectaron los datos.	Cuantitativa	Continua

2. Dataset 2: Auditoría

   Dataset seleccionado: Calidad del Aire en Colombia – Promedio Anual

   Portal: Datos Abiertos Colombia.

   Formato: XLSX

   Enlace:

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Calidad-del-Aire-en-Colombia-Promedio-Anual-/kekd-7v7h/data_preview

Clasificación de variables

Variable	Descripción de Variables	Tipo de Variable	Clasificación
ID estación	Dato propio de cada lugar donde se hizo el	Cualitativa	Nominal

	estudio		
Autoridad Ambiental	Quien realizó la auditoría de la zona	Cualitativa	Nominal
Estación	Lugar donde se realizó la recolección de datos	Cuantitativa	Nominal
Latitud	Parte de ubicación de la estación donde se recolectaron los datos.	Cuantitativa	Continua
Longitud	Parte de ubicación de la estación donde se recolectaron los datos.	Cuantitativa	Continua
Variable	identifica el contaminante atmosférico	Cualitativa	Nominal
Unidades	se utiliza para expresar los resultados de las	Cualitativa	Nominal

	mediciones realizado		
Tiempo de exposición	periodo durante el cual se mide la conta	Cualitativa	Nominal
Año	cuando se realicen las mediciones de la calidad del aire	Cuantitativa	Discreta
Promedio	valor promedio anual de la concentración del aire	Cuantitativa	Continua
Suma	valor total acumulado durante el año de las mediciones	Cuantitativa	Continua
No. de datos	cantidad de datos válidos. recopilados durante el año	Cuantitativa	Discreta
Representatividad temporal	porcentaje del tiempo de periodo evaluado que cuenta con registros	Cuantitativa	Continua
Excedencias límite	cantidad de veces que	Cuantitativa	Discreta

actual	se supero el limite permitido		
Porcentaje excedencias limit	porcentaje de mediciones que superan el límite	Cuantitativa	Continua
Mediana	valor que queda en la mitad de los datos	Cuantitativa	Continua
Percentil 98	valor que no supera el 98% de los datos	Cuantitativa	Continua
Máximo	valor más alto registrado durante el año	Cuantitativa	Continua
Fecha/horas del Maximo	fecha y hora en que se obtuvo el valor más alto	Cualitativa	Nominal
Mínimo	valor más bajo registrado en el año	Cuantitativa	Continua
Fecha/hora del mínimo	fecha y hora en que se obtuvo el valor	Cualitativa	Nominal

	más bajo		
Días de excedencias	número de días en que se superó el límite permitido	Cuantitativa	Discret
Código del departamento	número que identifica cada departamento	Cualitativa	Nominal
Nombre del departamento	nombre del apartamento donde se encuentra la estación	Cualitativa	Nominal
Código del municipio	número que identifica cada municipio	Cualitativa	Nominal
Nombre del municipio	nombre del municipio donde se encuentra la estación	Cualitativa	Nominal
Tipo de estación	indica que tipo de estación realiza las mediciones	Cualitativa	Nominal
Ubicación	lugar donde está ubicada la estación	Cualitativa	Nominal

3. Dataset 3: Auditoría

   Dataset seleccionado: Historical weather medellínl

   Portal: Kaggle.

   Formato: CSV

   Enlace: https://www.kaggle.com/datasets/jaiderlopez/historical-weather-medelln

Date (yyyy-mm-dd)	fecha en la que se registraron los cambios	cuantitativo	discreto
Max_temperature (°C)	máxima temperatura registrada en esa fecha	cuantitativo	discreto
Min_temperature (°C)	temperatura mínima registrada en esa fecha	cuantitativo	discreto
Rain (mm)	cantidad de lluvia registrada ese día	cuantitativo	continuo
Wind (km/h)	velocidad del viento registrada ese día	cuantitativo	discreto
Description	descripción de sí llovió si fue fuerte si fue pasito o nublo	cualitativa	ordinal

City	ciudad en la que se tomaron los resultados	cualitativa	nominal

2.3 Actividades de Apropiación del Conocimiento

1. **Auditoría del archivo CSV**

Inconsistencia 1: Datos faltantes en la columna de porcentaje de excedencias límite actual

Durante la revisión del conjunto de datos sobre la calidad del aire en Colombia, se identificaron dos registros sin información en la columna «Porcentaje de excedencias límite actual». Esto representa datos faltantes que pueden afectar algunos análisis. También se revisaron dos registros de una misma estación y variable, pero presentaban diferentes tiempos de exposición: uno de 1 hora y otro de 24 horas. Por esta razón, no se consideran duplicados.

Inconsistencia 2: Dato no numérico en representatividad temporal

Se identificó un registro con el valor «NA» en la columna «Representatividad temporal», mientras que los demás registros contienen valores numéricos. Esto puede representar un dato faltante o un valor no aplicable y afectar los análisis estadísticos de esa variable. Se recomienda verificar el registro original para determinar su significado.

Enlace Dataset:
https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Calidad-del-Aire-en-Colombia-Promedio-Anual-/kekd-7v7h/data_preview

2. **Dataset XLSX**

Después de analizar los datos contenidos en este dataset logramos identificar 2 errores

1. Revisando la estructura del datasets, se evidencio que hay inconsistencias en las clasificaciones de datos, en la normal climatológica de cada mes, cómo mayo (MAY) o junio (JUN), teniendo en cuenta que la gran mayoría de datos tienen la clasificación de cuantitativa/continua, hay datos con la clasificación cuantitativa/discreta. Al revisar los datos de texto y numéricos, encontramos esta inconsistencia. Pensamos que es un problema por el tema de la completitud, al estructurar los datos en la clasificación general, se deterioraron por que son distintas clasificaciones como ya menciones. Ejemplo del datasets:

PERIODO	PARÁME...	MUNICIPIO	DEPARTA...	ENE	FEB	MAR	ABR	MAY	JUN
1991-2020	PRECIPITACIÓN	El Encanto	Amazonas	180.2	214.8	296.4	317.5	339.3	300.2
1991-2020	PRECIPITACIÓN	La Chorrera	Amazonas	147.1	196.6	289.9	354.7	408	379
1991-2020	PRECIPITACIÓN	La Pedrera	Amazonas	354.3	347.7	411.7	421	411.4	326
1991-2020	PRECIPITACIÓN	La Pedrera	Amazonas	327.6	343.6	435.1	449.3	462.5	364.8
1991-2020	PRECIPITACIÓN	La Pedrera	Amazonas	315.8	301.5	378.1	386.5	370.6	350.3
1991-2020	PRECIPITACIÓN	Leticia	Amazonas	385.7	336.4	386.3	348.4	298.3	211.5
1991-2020	PRECIPITACIÓN	Miriti Paraná (Ca	Amazonas	292.2	315.9	367.6	413.7	396.4	329
1991-2020	PRECIPITACIÓN	Miriti Paraná (Ca	Amazonas	334.4	317.4	392.6	428.8	408.8	391.3

2. Al revisar la estructura del dataset, se identificaron inconsistencias en la columna correspondiente al total anual. Como se observa en el ejemplo, algunos registros presentan valores decimales, mientras que otros contienen valores enteros, lo que evidencia una falta de uniformidad en la estructura y clasificación de los datos.

Consideramos que esta inconsistencia puede estar relacionada con la clasificación de las variables y el proceso de consolidación de la información. La mayoría de los registros

corresponden a variables cuantitativas continuas, mientras que otros están clasificados como cuantitativos discretos. Al integrar estas diferentes clasificaciones en una estructura general, se pudieron generar inconsistencias en el tratamiento y la representación de los valores del total anual, afectando la uniformidad y la calidad de la información.

	OCT	NOV	DIC	ANU...
3.2	321.6	258.2	113	2,622.6
2.9	358.8	259.2	105.3	3,063
7.4	326.3	219.1	120.2	3,248.5
215	213.1	192.9	138.2	2,174.1

Enlace del Dataset: https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Normales-Climatol-gicas-de-Colombia/nsz2-kzcq/data_preview

2.4 Actividades de Transferencia de Conocimiento

2.4.1 Desarrollo del Diccionario de Datos

Para cada variable (columna) del dataset principal seleccionado, el equipo construirá una matriz registrando rigurosamente.

Datasets elegido:

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Calidad-del-Aire-en-Colombia-Promedio-Anual-/kekd-7v7h/data_preview

Nombre de la variable	**Nombre estandarizado**	**Clasificación estadística**	**Tipo de dato técnico**	**Descripción semántica**	**Unidad de medida o formato**
ID Estación	id_estacion	cualitativa nominal	int	Identificador único asignado por el subsistema de información sobre la calidad del aire SISAIRE	Código de identificador
Autoridad Ambiental	Autoridad_ambiental	cualitativa nominal	String	Autoridad ambiental encargada de operar el sistema de vigilancia de la calidad del	Texto

				aire en la jurisdicción donde se ubica la estación de monitoreo	
Estación	estacion	cualitativa nominal	String	Nombre que se le designa a la estación de monitoreo	Texto
Latitud	latitud	cuantitativa continua	int	coordenada geográfica que indica la latitud de la ubicación de la estación	Grados decimales (°)
Longitud	longitud	cuantitativa continua	int	Coordenada geográfica en la que se indica las longitudes en	Grados decimales (°)

				donde está ubicada la estación	
Variable	variable	cualitativa nominal	String	Contaminante atmosférico o variable meteorológica que se mide en la estación de monitoreo atmosférico	Texto
Unidades	unidades	cualitativa nominal	String	unidad de medida empleada para expresar el contaminante atmosférico o variable meteorológica	Texto

Tiempo de exposición (horas)	tiempo_exposicion_h	cualitativa continua	int	periodo de referencia específico establecido en la normativamente establecidos para tomar los niveles de concentración de un contaminante atmosférico	Horas
Año	ano	cuantitativa discreta	int	año en el que se realizó la medición en la respectiva estación	AAAA
Promedio	promedio	cualitativa continua	int	promedio anual del nivel de	Según la unidad del contaminante

				inmisión o concentración del contaminante atmosférico	
Suma	suma	cualitativa continua	float	total acumulado anual del nivel de inmisión o concentración de inmisión a nivel estándar	Según la unidad del contaminante
No. de datos	n_datos	cuantitativa discreta	int	cantidad total de datos validados recopilados a lo largo del año	Número entero
Representatividad Temporal	representatividad_tem	cualitativa continua	int	porcentaje total de	Porcentaje (%)

	poral			tiempo de un periodo tiene datos válidos registrados	
Excedencias límite actual	excedencias_limite_actual	cualitativa discreta	int	número total de veces en el que el contaminante ha superado el nivel máximo permisible	Número entero o porcentaje
Porcentaje excedencias límite actual	porcentaje_excedencias_limite_actual	cualitativa continua	int	proporción determinada por el número de veces en el que el contaminante atmosférico ha superado el límite máximo	Porcentaje

				permisible	
Mediana	mediana	cuantitativa nominal	int	mediana anual del valor de la variable atmosférica	Según unidad del contaminante
Percentil 98	porcentil_98	cuantitativa continua	int	medida estadística que indica el valor del contaminante atmosférico o de la variable meteorológica por debajo del cual se encuentra el 98% de los datos en el grupo durante el año de medición	Según unidad del contaminante

Máximo	maximo	cuantitativa continua	int	valor más alto tomado de la variable atmosférica durante el año de medición	Según unidad del contaminante
Fechas/horas del máximo	fecha_horas_maximo	cualitativa nominal	string	fecha y hora en la que se registró el máximo	Fecha y hora
Mínimo	minimo	cuantitativa continua	int	valor más bajo registrado de la variable atmosférica durante el año de medición	Según unidad del contaminante
Fechas/horas del mínimo	fecha_horas_minimo	cualitativa nominal	string	fecha y hora en el se	Fecha y hora

				registró el mínimo	
Días de excedencias	dias_excedencias	cuantitativa discreta	int	número de días en el que el contaminante atmosférico ha superado el máximo permisible	Numero de dias
Código del Departamento	codigo_departamento	cuantitativa continua	int	código DANE asignado al departamento	Código numérico
Nombre del Departamento	nombre_departamento	cualitativa nominal	string	Nombre del departamento donde se realizó el estudio	Texto
Código del Municipio	codigo_municipal	cualitativa nominal	int	Código del municipio	Código numérico

				donde se realizó el estudio	
Nombre del Municipio	nombre_municipio	cualitativa nominal	string	Nombre del municipio donde se realizó el estudio	Texto
Tipo de Estación	tipo_estacion	cualitativa nominal	string	Descripción de si la estación es móvil o se queda en un punto fijo	Texto
Ubicación	ubicaion	cualitativa nominal	Array	Ubicación en donde se encuentra la estación	Coordenadas o descripción textual

Referencias:

Primer punto:

https://www.wisecleaner.com/think-tank/291-Differences-between-xls-xlsx-xlsm-xlsb-and-csv.html

Estilo mapa conceptual: https://www.sitioincreible.com/

Kaggle: https://www.kaggle.com/

Datos Abiertos Bogotá. (s. f.). Plataforma Distrital de Datos Abiertos.:

https://datosabiertos.bogota.gov.co/

Datos Abiertos Bogotá. (s. f.). Plataforma Distrital de Datos Abiertos.

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Calidad-del-Aire-en-Colombia-Promedio-Anual-/kekd-7v7h/data_preview

Kaggle / jaider lopez / 2024 /

https://www.kaggle.com/datasets/jaiderlopez/historical-weather-medelln/data

datosgov.com

Datos Abiertos Bogotá. (s. f.). Plataforma Distrital de Datos Abiertos:

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Normales-Climatol-gicas-de-Colombia/nsz2-kzcq/data_preview